

# SuGaR

论文：《SuGaR: Surface-Aligned Gaussian Splatting for Efficient 3D Mesh Reconstruction and High-Quality Mesh Rendering》

地址： <https://arxiv.org/abs/2311.12775>

年份：CVPR 2024

## Introduction

任务：从 3D 高斯中提取 mesh

技术贡献：

- (1) 使用正则项来使 gaussian 贴合物体的表面，使得 gaussian 的分布在几何上是正确的；
- (2) 提取 mesh 之后，将 gaussian 绑定在 mesh 上进行优化，使得 mesh 更加准确。

## Method

主要分为 3 个步骤：引入正则项优化 gaussian，使用泊松重建提取 mesh，将 gaussian 绑定在 mesh 上继续优化得到更准确的 mesh。

### Aligning the Gaussians with the Surface

首先考虑一个密度函数  $d$ ：

$$d(p) = \sum_g \alpha_g \exp\left(-\frac{1}{2}(p - \mu_g)^T \Sigma_g^{-1}(p - \mu_g)\right)$$

其中  $p$  空间中的一个点， $\mu_g, \Sigma_g, \alpha_g$  分别表示 gaussian 的中心、协方差矩阵和不透明度。

我们想要设计一个正则项  $|d(p) - \bar{d}(p)|$ ，让 gaussian 能够贴合物体的表面，所以需要知道在理想情况下的  $\bar{d}(p)$  会是什么形式。

- (1) 首先是对  $p$  做约束，使其是接近物体表面的点，这样的话离它最近的 gaussian  $g^*$  会对  $d(p)$  贡献最大，且远大于其他 gaussian，可以将  $d(p)$  近似为这一个 gaussian 的贡献：

$$\alpha_g^* \exp\left(-\frac{1}{2}(p - \mu_{g^*})^T \Sigma_{g^*}^{-1}(p - \mu_{g^*})\right)$$

- (2) 然后让 3d gaussian 尽可能是一个扁平的圆盘，这样就能更好地贴合 mesh 的表面。因此就会有

$$(p - \mu_g)^T \Sigma_g^{-1}(p - \mu_g) \approx \frac{1}{s_g^2} \langle p - \mu_g, n_g \rangle^2$$

其中  $s_g$  和  $n_g$  是最短轴的长度和方向。

上式可以按下面的过程推导得到 (论文作者在 github issue 中给出的回答

<https://github.com/Anttwo/SuGaR/issues/2>)：

$\Sigma_g^{-1}$  可以写为  $R_g S_g^{-1} S_g^{-1} R_g^T$ , 其中  $S_g$  就是表示 scaling 的对角阵, 由于现在 gaussian 是一个扁平的圆盘, 因此对角线上会有一个特别小的值, 即  $s_g$ ,  $S_g^{-1}$  也会是一个对角阵, 且对角线上会有两个特别小的值, 还有一个值为  $\frac{1}{s_g}$ , 可以将这个值记为是对角线上第  $i$  个元素。对  $(p - \mu_g)$  左乘  $S_g^{-1} R_g^T$  就等价于将  $(p - \mu_g)$  往  $R_g$  的第  $i$  列上做投影, 并将结果做 scaling  $\frac{1}{s_g}$ 。  $R_g$  的第  $i$  列向量是  $n_g$ , 所以就可以得到上式。

(3) 最后我们希望 gaussian 要么是全透明的, 要么是完全不透明的, 因此设置  $\alpha_g$  为 1。

如果 gaussian 能满足以上 3 点, 那么  $d(p)$  就会变为  $\bar{d}(p)$ :

$$\bar{d}(p) = \exp\left(-\frac{1}{2s_g^2} \langle p - \mu_g^*, n_g^* \rangle^2\right)$$

这样的话将  $|d(p) - \bar{d}(p)|$  加到 loss 中就能有效地约束 gaussian, 使其贴合物体表面。但作者对上面推出的结果稍微转化一下, 变为 SDF 相关的 loss, 能有更好的效果。

想要计算 SDF, 先得有距离, 距离是  $|\langle p - \mu_g, n_g \rangle|$ , 而这刚好是上面  $\bar{d}(p)$  中的一项:

$$\bar{d}(p) = \exp\left(-\frac{1}{2s_g^2} \bar{f}(p)^2\right)$$

因此就有:

$$\bar{f}(p) = \pm s_g^* \sqrt{-2 \log(\bar{d}(p))}$$

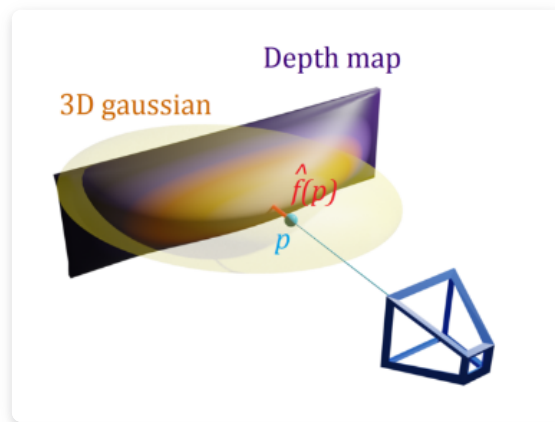
假设在理想场景中, gaussian 贴合物体表面, 也就是满足上面提到的 3 个性质, 那么有  $d(p) = \bar{d}(p)$ , 可以将上式中的  $\bar{d}(p)$  替换为  $d(p)$ :

$$f(p) = \pm s_g^* \sqrt{-2 \log(d(p))}$$

我们认为  $f(p)$  就是理想情况下的距离函数。因此设计正则项为:

$$\mathcal{R} = \frac{1}{|\mathcal{P}|} \sum_{p \in \mathcal{P}} |\hat{f}(p) - f(p)|$$

其中  $f(p)$  是理想情况下的距离,  $\hat{f}(p)$  是估计的距离, 是  $p$  到由 gaussian 组成的表面之间的距离。



文章说计算  $\hat{f}(p)$  是一个 priori challenging, 所以采用计算深度的方式来近似 (也是参考论文作者在 github issue 中给出的回答 <https://github.com/Anttwo/SuGaR/issues/2>):

可以渲染 gaussian 的深度图, 而这个深度图可以近似代表场景中物体的表面位置, 对于空间点中  $p$ , 在

给定视角下，可以将其投影到 2d 得到对应坐标下的深度值，这就是物体表面的深度，然后我们也知道  $p$  的深度，两者做差即可得到一个近似的距离。

通过在高斯分布上采样来得到  $p$ ：

$$p \sim \prod_g \mathcal{N}(\cdot; \mu_g, \Sigma_g)$$

还添加了一项 loss 使得  $f$  和  $\bar{f}$  的 normal 保持一致：

$$\mathcal{R}_{\text{Norm}} = \frac{1}{|\mathcal{P}|} \sum_{p \in \mathcal{P}} \left\| \frac{\nabla f(p)}{\|\nabla f(p)\|_2} - n_{g^*} \right\|^2$$

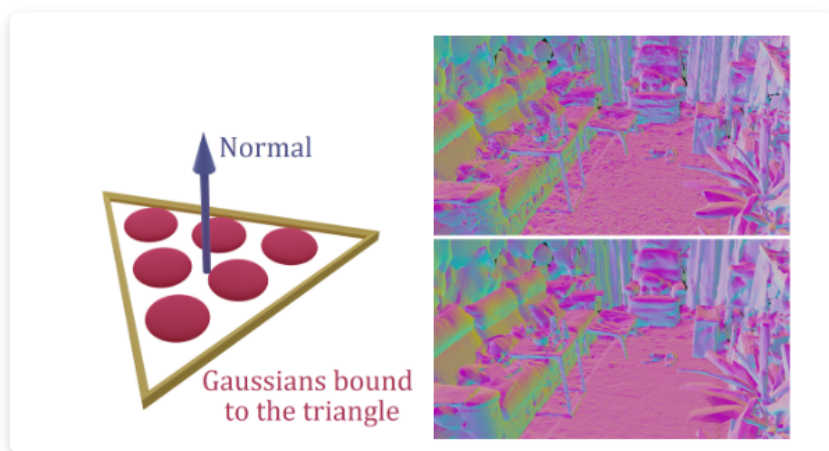
## Efficient Mesh Extraction

TBD.

需要先了解泊松重建原理再来看这一节

## Binding New 3D Gaussians to the Mesh

通过泊松重建得到 mesh 后，将 gaussian 绑定在 mesh 上进行优化来对 mesh 进行 refine。



对 mesh 上每个三角面片，初始化  $n$  个 gaussian，然后根据面片边长和朝向设置它们的 scale 和 rotation 等。

## Experiments

训练流程：先不加入正则项训练 7000 步；然后加入一个对透明度的 entropy loss 训练 2000 步，目的是让 gaussian 变得完全不透明或者完全透明；然后将不透明度低于 0.5 的 gaussian 去除，引入正则化项训练 6000 步。这样一共训练 15000 步。

对 mesh 进行 refine 会进行 2000，7000，或 15000 步。