

# SAL

论文：《SAL: Sign Agnostic Learning of Shapes from Raw Data》

地址：<https://arxiv.org/abs/1911.10414>

年份：CVPR 2020

## Introduction

任务：表面重建

技术贡献：

- (1) 提出了重建物体表面时将 SDF 初始化为球的几何初始化方法；
- (2) 证明了基于论文的方法训练的 SDF 具有 plane reproduction 的性质。

## Method

首先是问题设定，文章希望从 raw data (如不带法向的点云, triangle soup) 中学习一个 SDF，用于重建表面。

文章定义了训练的 loss：


$$\text{loss}(\boldsymbol{\theta}) = \mathbb{E}_{\mathbf{x} \sim D_{\mathcal{X}}} \tau(f(\mathbf{x}; \boldsymbol{\theta}), h_{\mathcal{X}}(\mathbf{x}))$$

其中  $D_{\mathcal{X}}$  是由输入数据  $\mathcal{X}$  确定的分布， $h_{\mathcal{X}}(\mathbf{x})$  是度量到  $\mathcal{X}$  的无符号距离， $\tau$  是一个度量相似性的函数。

要求  $\tau$  满足以下两个性质：

1. Sign agnostic:  $\tau(-a, b) = \tau(a, b)$
2. Monotonic:  $\frac{\partial \tau}{\partial a}(a, b) = \rho(a - b)$

其中  $\rho$  是一个单调递增函数，且  $\rho(0) = 0$ 。 $\tau$  的一个例子是  $\tau(a, b) = ||a| - b|$



这是一个一维的例子， $\mathcal{X} = \{x_0\}$ ,  $h_{\mathcal{X}}(x) = |x - x_0|$  是无符号距离， $\tau(a, b) = ||a| - b|$ ，上面定义的 loss 就会要求最小化图上黄色区域的面积，最终得到的结果  $f(\mathbf{x}; \boldsymbol{\theta})$  会是  $h_{\mathcal{X}}(x)$  的有符号版本。

$h_{\mathcal{X}}(x)$  由两种选择：

$$h_2(z) = \min_{x \in \mathcal{X}} ||z - x||_2$$

$$h_0(z) = \begin{cases} 0 & z \in \mathcal{X} \\ 1 & z \notin \mathcal{X} \end{cases}$$

对于  $D_{\mathcal{X}}$ , 选择是在每一处点  $\mathbf{x} \in \mathcal{X}$  投射一个各向同性的高斯  $\mathcal{N}(\mathbf{x}, \sigma^2 I)$  以及狄拉克  $\delta$  函数 (对于  $h_0(z)$ ), 这样的话 loss 就是:

$$\text{loss}(\boldsymbol{\theta}) = \mathbb{E}_{\mathbf{z} \sim \mathcal{N}_{\sigma}(\mathcal{X})} ||f(\mathbf{x}; \boldsymbol{\theta})| - 1|^l + \mathbb{E}_{\mathbf{x} \sim \mathcal{X}} |f(\mathbf{x}; \boldsymbol{\theta})|^l$$

对于  $h_2(z)$ , 有

$$\text{loss}(\boldsymbol{\theta}) = \mathbb{E}_{\mathbf{z} \sim \mathcal{N}_{\sigma}(\mathcal{X})} ||f(\mathbf{x}; \boldsymbol{\theta})| - h_2(z)|^l$$

网络选用 MLP

**Neural architecture.** Although SAL can work with different parametric models, in this paper we consider a multilayer perceptron (MLP) defined by

$$f(\mathbf{x}; \boldsymbol{\theta}) = \varphi(\mathbf{w}^T f_{\ell} \circ f_{\ell-1} \circ \dots \circ f_1(\mathbf{x}) + b), \quad (8)$$

and


$$f_i(\mathbf{y}) = \nu(\mathbf{W}_i \mathbf{y} + \mathbf{b}_i), \mathbf{W} \in \mathbb{R}^{d_i^{out} \times d_i^{in}}, \mathbf{b}_i \in \mathbb{R}^{d_i^{out}}, \quad (9)$$

where  $\nu(a) = (a)_+$  is the ReLU activation, and  $\boldsymbol{\theta} = (\mathbf{w}, b, \mathbf{W}_{\ell}, \mathbf{b}_{\ell}, \dots, \mathbf{W}_1, \mathbf{b}_1)$ ;  $\varphi$  is a strong non-linearity, as defined next:

## Geometric network initialization

接下来希望去初始化 MLP 使得一开始为半径为  $r$  的球体。

下面就是证明 2 个结论, 选用其中给出的初始化参数即可将 MLP 几何初始化为球体。



上图是 MLP 中线性层宽度为 100, 200 和 2000 的情况, 可以看到线性层宽度越宽, 初始化结果越接近球体。这是由于后面结论的推导用到了大数定律, 宽度越宽则越接近期望。

**Theorem 1.** Let  $f$  be an MLP (see equations 8-9). Set, for  $1 \leq i \leq \ell$ ,  $\mathbf{b}_i = 0$  and  $\mathbf{W}_i$  i.i.d. from a normal distribution  $\mathcal{N}(0, \frac{\sqrt{2}}{\sqrt{d_i^{out}}})$ ; further set  $\mathbf{w} = \frac{\sqrt{\pi}}{\sqrt{d_{\ell}^{out}}} \mathbf{1}$ ,  $c = -r$ . Then,  $f(\mathbf{x}) \approx \varphi(\|\mathbf{x}\| - r)$ .

## Proof of Theorem 1

定理 1 的大致意思是，先不看最后的  $\mathbf{w}$  和  $c$ ，通过指定中间层的参数，使最后一层隐藏层的输出的模长大小为  $\|\mathbf{x}\|_2$ 。

具体是让  $\mathbf{W}_i$  的值是  $\mathcal{N}(0, \frac{2}{d_i^{out}})$  的独立同分布， $\mathbf{b}_i = 0$ 。我们要证明的是经过隐藏层  $g(\mathbf{x}) = f_{l-1} \circ \dots \circ f_1$  后，有  $\|g(\mathbf{x})\| \approx \|\mathbf{x}\|$ 。

考虑一层隐藏层的情况即可，因为经过一层后有上述性质，那么经过任意层后模长还会是一样的。所以考虑  $h(\mathbf{x}) = \nu(\mathbf{W}\mathbf{x} + \mathbf{b})$ ， $\mathbf{W} \in \mathbb{R}^{d^{out} \times d^{in}}$ ， $\mathbf{x} \in \mathbb{R}^{d^{in}}$ ， $\mathbf{b} \in \mathbb{R}^{d^{out}}$ 。记  $k = d^{out}$

先把矩阵  $\mathbf{W}$  拆成行来看，那么就会有  $k$  个  $d^{in}$  维的向量  $\mathbf{W}_{i,:}$ ，然后与  $\mathbf{x}$  点乘后就是标量。这里相当于提前将隐藏层结果变为标量方便证明模长。

$$\|h(\mathbf{x})\|^2 = \sum_{i=1}^k \nu(\mathbf{W}_{i,:} \cdot \mathbf{x})^2 = \frac{1}{k} \sum_{i=1}^k \nu(\sqrt{k} \mathbf{W}_{i,:} \cdot \mathbf{x})^2$$

然后是利用大数定律将离散求和转换为算期望连续的形式，有

$$\|\mathbf{x}\|^2 \int_{\mathbb{R}^k} \nu(\mathbf{y} \cdot \frac{\mathbf{x}}{\|\mathbf{x}\|})^2 \mu(\mathbf{y}) d\mathbf{y}$$

相当于  $\sqrt{k} \mathbf{W}_{i,:}$  是随机变量序列，其满足独立同分布的  $\mathcal{N}(0, 2)$ 。

然后是做了一步变换  $\mathbf{y} = \mathbf{R}\mathbf{y}'$ ，其中  $\mathbf{R}$  是  $k \times k$  的正交阵，且使  $\mathbf{R}^T \frac{\mathbf{x}}{\|\mathbf{x}\|} = (1, 0, \dots, 0)^T$ ，这样做的目的是消除  $\mathbf{x}$  这个变量。这样就会有

$$\mathbf{y} \cdot \frac{\mathbf{x}}{\|\mathbf{x}\|} = \mathbf{R}\mathbf{y}' \cdot \frac{\mathbf{x}}{\|\mathbf{x}\|} = \mathbf{y}'^T \mathbf{R}^T \frac{\mathbf{x}}{\|\mathbf{x}\|} = \mathbf{y}'^T (1, 0, \dots, 0)^T = y_1$$

其中  $y_1$  是  $\mathbf{y}'$  的第 1 个元素。

继续前面的式子，代换之后有

$$\|\mathbf{x}\|^2 \int_{\mathbb{R}^k} \nu(y_1)^2 \mu(\mathbf{R}\mathbf{y}') d(\mathbf{R}\mathbf{y}')$$

先看  $\mu$ ，参照 <https://zhuanlan.zhihu.com/p/650679177>，多元正态分布有密度旋转不变性，因此  $\mu(\mathbf{R}\mathbf{y}') = \mu(\mathbf{y}')$ ，再看  $d$  后面的项， $\mathbf{R}$  相当于就是 Jacobian，即有  $d\mathbf{y} = d(\mathbf{R}\mathbf{y}') = |\det(\mathbf{R})| d\mathbf{y}'$ ，正交阵的行列式为 1，所以  $d\mathbf{y} = d\mathbf{y}'$ 。(论文中这里的推导并没有这么具体，这是按照我的个人理解来的)

经过变换后，上式会变为

$$\|\mathbf{x}\|^2 \int_{\mathbb{R}^k} \nu(y_1)^2 \mu(\mathbf{y}') d\mathbf{y}'$$

后面一步是将多元高斯的积分转换为一元高斯的积分，这一步具体原理没在网上找到。

$$\|\mathbf{x}\|^2 \int_{\mathbb{R}} \nu(y_1)^2 \mu(y_1) dy$$

$\nu$  用的是 ReLU，只在正半轴有值，所以做个一个对称

$$\frac{\|\mathbf{x}\|^2}{2} \int_{\mathbb{R}} y_1^2 \mu(y_1) dy$$

最后积分里的式子相当于算期望  $E[x^2]$ ，因此值为  $\mu^2 + \sigma^2$  即 2。所以最终结果为  $\|\mathbf{x}\|^2$  论文最后还考虑了有 skip connection 的情况，比较简单。

**Theorem 2.** Let  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  be an MLP with ReLU activation,  $\nu$ , and a single hidden layer. That is,  $f(\mathbf{x}) = \mathbf{w}^T \nu(\mathbf{W}\mathbf{x} + \mathbf{b}) + c$ , where  $\mathbf{W} \in \mathbb{R}^{d^{out} \times d}$ ,  $\mathbf{b} \in \mathbb{R}^{d^{out}}$ ,  $\mathbf{w} \in \mathbb{R}^{d^{out}}$ ,  $c \in \mathbb{R}$  are the learnable parameters. If  $\mathbf{b} = 0$ ,  $\mathbf{w} = \frac{\sqrt{2\pi}}{\sigma^{d^{out}}} \mathbf{1}$ ,  $c = -r$ ,  $r > 0$ , and all entries of  $\mathbf{W}$  are i.i.d. normal  $\mathcal{N}(0, \sigma^2)$  then  $f(\mathbf{x}) \approx \|\mathbf{x}\| - r$ . That is,  $f$  is approximately the signed distance function to a  $d-1$  sphere of radius  $r$  in  $\mathbb{R}^d$ , centered at the origin.

定理 2 的大致意思是，将隐藏层参数设为定理 1 中给出的值，令最后一层的  $\mathbf{w} = \frac{\sqrt{2\pi}}{\sigma^{d^{out}}} \mathbf{1}$ ,  $c = -r$ ，就会使输出的  $f(\mathbf{x}) = \|\mathbf{x}\| - r$ 。

这里也记  $k = d^{out}$ ， $\mathbf{W}$  的值属于  $\mathcal{N}(0, \sigma^2)$ 。前面的推导过程基本与定理 1 思想一致，主要是看最后一个等式

$$\frac{\sqrt{2\pi}\|\mathbf{x}\|}{2\sigma} \int_{\mathbb{R}} |v_1| \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{v_1^2}{2\sigma^2}} dv_1$$

积分内是偶函数，利用对称性就有

$$\frac{\sqrt{2\pi}\|\mathbf{x}\|}{\sigma} \int_0^{+\infty} v_1 \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{v_1^2}{2\sigma^2}} dv_1$$

积分里的原函数很好求，最终结果仍是  $\|\mathbf{x}\|$ 。

## Properties

TBD.

## Experiments



Failure case 是不能重建细的物体，可能是因为细的部分采样的点少，模型不能很好的建模这一部分的距离关系。